



INSTITUTO FEDERAL
SÃO PAULO

Mapeando Padrões de Mortalidade com SOM

Uma Análise Exploratória com Dados do SUS

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

Orientador: Professor Dr. Cleber Silva de Oliveira

Coorientador: Professor Dr. Thiago Schumacher Barcelos

Fonte de Dados

- Utilização dos arquivos do Sistema de Informação sobre Mortalidade (SIM);
- Dados Abertos Oficiais com maior informação sobre a saúde da população brasileira;

Grupo de Pesquisa



Gabriela Santana Camilo

Comorbidades na Doença de Alzheimer



Bianca Toledo

Ataque cardíaco na população feminina



Dr. Cleber de Oliveira

Orientador



Gabriel Barboza

Comorbidades na Doença de Alzheimer



Giselle Silva


Ataque cardíaco na população feminina




Dr. Thiago Schumacher

Co-orientador

Diagrama de Atividades ETL





Volumetria dos Dados Pós-ETL

Over
View

Volumetria Inicial (CSV)

15,1 Mi

Volumetria para Análise (SQL)

14,6 Mi

Volumetria Perdida


525,8 Mil

Porcentagem de perda

3,6%


Diferença entre volumetrias: CSV vs SQL

● Volumetria CSV ● Volumetria SQL




Diferença das volumetrias por ano

● Volumetria CSV ● Volumetria SQL



Início da Análise de Dados



<https://danielteofilo.wordpress.com/2015/02/16/kdd-knowlegde-discovery-in-database/>

Knowledge Discovery in Databases, KDD

Seleção de Dados

Indexação





Figura 5 – Plano de execução da consulta sem índice aplicado na coluna CAUSABAS.



Comparação da complexidade computacional entre buscas sem e com índice.

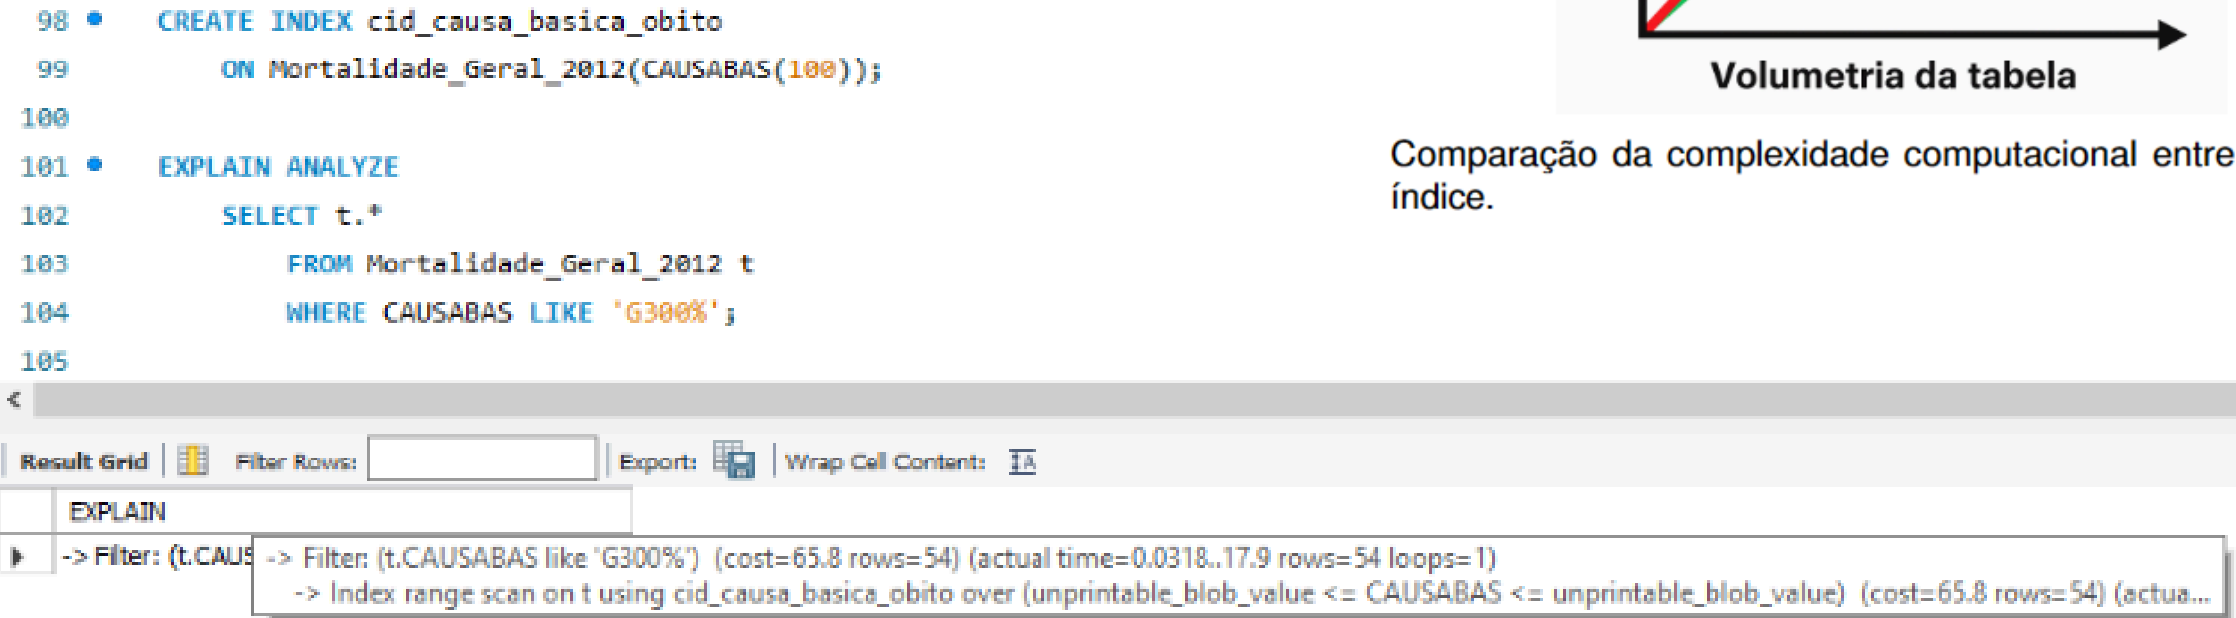


Figura 6 – Plano de execução da consulta com índice aplicado na coluna CAUSABAS.

```
DELIMITER $$  
CREATE PROCEDURE sim_data.SPR_Enriquece_Analise(IN tabela VARCHAR(100))  
BEGIN  
    DECLARE CIDs VARCHAR(100);  
    DECLARE TabelaFiltrada VARCHAR(100);  
    DECLARE nomeTabelaFinal VARCHAR(100);  
  
    SET CIDs := '''F000''', '''F001''', '''F002''', '''F009''', '''G300''', '''G301''', '''G308''', '''G309'''; -- CIDs de Alzheimer  
    SET TabelaFiltrada := CONCAT(tabela, '_filtrada');  
    SET nomeTabelaFinal := CONCAT(tabela, '_analise');
```

CID	Descrição
F00.0	Demência na doença de Alzheimer de início precoce
F00.1	Demência na doença de Alzheimer de início tardio
F00.2	Demência na doença de Alzheimer, tipo atípico ou misto
F00.9	Demência na doença de Alzheimer, não especificada
G30.0	Doença de Alzheimer de início precoce
G30.1	Doença de Alzheimer de início tardio
G30.8	Outras formas de doença de Alzheimer
G30.9	Doença de Alzheimer, não especificada

Trecho da Procedure SPR_Enriquece_Analise

Seleção de Dados

União e Exportação

```
CREATE TABLE tb_alvo as
SELECT *, 2012 as ANO FROM Mortalidade_Geral_2012_filtrada
UNION ALL
SELECT *, 2013 AS ANO FROM Mortalidade_Geral_2013_filtrada
UNION ALL
SELECT *, 2014 AS ANO FROM Mortalidade_Geral_2014_filtrada
UNION ALL
SELECT *, 2015 AS ANO FROM Mortalidade_Geral_2015_filtrada
UNION ALL
SELECT *, 2016 AS ANO FROM Mortalidade_Geral_2016_filtrada
UNION ALL
SELECT *, 2017 AS ANO FROM Mortalidade_Geral_2017_filtrada
UNION ALL
SELECT *, 2018 AS ANO FROM Mortalidade_Geral_2018_filtrada
UNION ALL
SELECT *, 2019 AS ANO FROM Mortalidade_Geral_2019_filtrada
UNION ALL
SELECT *, 2020 AS ANO FROM Mortalidade_Geral_2020_filtrada
UNION ALL
SELECT *, 2021 AS ANO FROM Mortalidade_Geral_2021_filtrada
UNION ALL
SELECT *, 2022 AS ANO FROM Mortalidade_Geral_2022_filtrada;
```

dados_filtrados.csv sql U X

C: > Users > USER > Documents > Facul > TCC > work_in_progress > sql > dados_f

1	"CONTADOR";"ORIGEM";"TIPOBITO";"DTOBITO";"
2	"42081";"1";"2";"28042012";"1800";"";"1807
3	"52106";"1";"2";"12072012";"1440";"";"0710
4	"25135";"1";"2";"30072012";"1930";"";"0309
5	"10487";"1";"2";"29012012";"1745";"";"2306
6	"10560";"1";"2";"27042012";"1300";"";"1304
7	"16184";"1";"2";"14122012";"1240";"";"1509
8	"32903";"1";"2";"09022012";"1340";"";"0201
9	"33762";"1";"2";"30042012";"1515";"";"2110
10	"222";"1";"2";"03032012";"1520";"";"131219
11	"5936";"1";"2";"18122012";"0900";"";"14071
12	"6406";"1";"2";"31032012";"0210";"";"07041
13	"2578";"1";"2";"28052012";"0545";"";"06011
14	"4300";"1";"2";"25042012";"0023";"";"0000"



Pré-processamento

Criação do Notebook e Carregamento de Dados

[2]: # Importando os pacotes

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

[3]: # Importando a dataframe - todos como str

```
df = pd.read_csv('dados_filtrados.csv', sep=';', dtype=str)
```

[4]: df


	CONTADOR	ORIGEM	TIPOBITO	DTOBITO	HORAOBITO	NATURAL0	DTNASC	IDADE	SEXO	RACACOR	...	STDOEPIDEM	STDONOVA	DTCADINV	TPOBITO
0	42081	1	2	28042012	1800	NaN	18071914	497	2	4	...	0	1	NaN	
1	52106	1	2	12072012	1440	NaN	07101944	467	1	1	...	0	1	NaN	
2	25135	1	2	30072012	1930	NaN	03091938	473	1	1	...	0	1	NaN	
3	10487	1	2	29012012	1745	NaN	23061928	483	1	1	...	0	1	NaN	
4	10560	1	2	27042012	1300	NaN	13041920	492	2	1	...	0	1	NaN	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
211588	1514999	1	2	22122022	0857	843	15041939	483	2	1	...	0	1	NaN	
211589	1515062	1	2	23082022	0920	831	01031953	469	2	4	...	0	1	NaN	
211590	1515229	1	2	05072022	2000	833	24071938	483	2	1	...	0	1	NaN	
211591	1515340	1	2	06072022	2358	190	26101930	491	2	1	...	0	1	NaN	
211592	1515396	1	2	06072022	0655	831	26111929	492	2	4	...	0	1	NaN	

211593 rows × 68 columns



Pré-processamento

Deleção de Nulos e Imputação de Dados



Pré-processamento

Coluna	Descrição	Ação	Tipo	% Dados Faltantes
ESC2010	Escolaridade última série concluída (falecido)	Manter	Int	7%
ESCMAE2010	Escolaridade última série concluída (mãe)	Descartar	-	100%
DIFDATA	Diferença entre datas	Descartar	-	-
STDOEPIDEM	Status DO Epidemiológica	Descartar	Int	-
STDONOVA	Status DO Nova	Descartar	Int	-
DTCADINV	Data do cadastro de investigação	Manter	Str	-
TPOBITOCOR	Momento da ocorrência do óbito	Descartar	Int	-
DTCONINV	Data da conclusão da investigação	Manter	Str	-
DTCADINF	Indica se houve investigação	Manter	Str	-
MORTEPARTO	Falta descrição na fonte	Descartar	-	-
DTCONCASO	Data da conclusão do caso	Descartar	Str	-

Transformação

Codificação CIDs e Normalização dos Dados

```
[33]: # Transformando o CID's em colunas numéricas:

def substituir_letras(cid):
    # Verifica se é string
    if isinstance(cid, str):
        aux = ""

        for digito in cid:
            # verifica se é Letra (a - z)
            if digito.isalpha():
                # ord -> converte caracteres em inteiros
                numero = ord(digito.upper()) - ord('A') + 1
                # concatena à string auxiliar criada
                aux += str(numero)

            # se for numero, continua
            else:
                aux += digito
        return aux
    return cid
```

Figura 18 – Função utilizada para codificação das letras presentes nos códigos CID.

```
scaler = RobustScaler()
df_scaled = scaler.fit_transform(df_ocup.select_dtypes(include='number'))
```

Letra	Número
A	1
B	2
C	3
D	4
E	5
F	6
G	7
H	8
I	9
J	10
K	11
L	12
M	13
N	14
O	15

Pré-processamento

Outliers




Figura 19 – Boxplot para identificação de *outliers* nas variáveis analisadas.



O que é Mapa SOM

O Self Organizing Map (SOM) é uma Rede Neural de aprendizado não supervisionado, o que significa que é um tipo de modelo que aprende padrões a partir dos dados sem utilizar rótulos (ou categorias) previamente definidos.




O que é Mapa SOM

- Neurônios e pesos;
- Métricas de distâncias;
- Adaptando os dados para o SOM.



Mineração de Dados


Mapa SOM: Por que a escolha?




- Dados complexos e com alta dimensionalidade;
- Baixa correlação linear;
- Explorar a existência de padrões;
- Não tem rótulo definido;



Início da Mineração de Dados



<https://danielteofilo.wordpress.com/2015/02/16/kdd-knowlegde-discovery-in-database/>



INSTITUTO FEDERAL
SÃO PAULO


Visualização de comorbidades em óbitos por Alzheimer no Brasil (2012–2022) usando Mapas Auto-Organizáveis (SOMs)



Motivação

A **expectativa de vida** no Brasil **cresceu**
cerca de **55%** nos últimos 12 anos
IBGE 2022

Globalmente, a **demência afetava 55 milhões** de pessoas em 2019 e deverá
alcançar **139 milhões até 2050**, devido ao envelhecimento populacional.
OMS 2021



Motivação

Entre 2.618 pacientes com Alzheimer, **55,1% tinham hipertensão**, 38,2% osteoartrite, 32,3% depressão, 25,7% diabetes e 22,7% doenças cerebrovasculares, **elevando o risco de morte.**

Wang et al 2025




Aplicação do SOM

Variáveis selecionadas para o treinamento


```
df_training = df[
    [
        'LINHAA_1', 'LINHAA_2', 'LINHAA_3', 'LINHAA_4', 'LINHAB_1', 'LINHAB_2', 'LINHAB_3', 'LINHAB_4',
        'LINHAC_1', 'LINHAC_2', 'LINHAC_3', 'LINHAC_4', 'LINHAD_1', 'LINHAD_2', 'LINHAD_3', 'LINHAD_4',
        'LINHAII_1', 'LINHAII_2', 'LINHAII_3', 'LINHAII_4', 'LINHAII_5', 'LINHAII_6', 'LINHAII_7', 'LINHAII_8', 'LINHAII_9',
        'CAUSABAS', 'CAUSABAS_0'
    ]
]
```




Aplicação do SOM



Aplicação do SOM



Aplicação do SOM



- Cluster 1: Composição predominante da coluna CAUSA_BAS
- Cluster 2: LINHAA_1
- Cluster 3: LINHAII_1

Ativação dos Clusters

- Cluster 1: CAUSA_BAS

Indica a **causa básica** da morte, ou seja, a doença ou condição que iniciou a cadeia de eventos que levou ao óbito

- Cluster 2: LINHAA

Indica a **causa imediata** da morte (a última condição que levou ao óbito)


- Cluster 3: LINHAII

Indica **condições significativas** que contribuíram para a morte, mas que não fazem parte da cadeia principal de eventos que levou ao óbito



Cluster 1

Neurônios: (3,0), (3,1), (3,2), (4,0), (4,1), (4,2), (5,0), (5,1) e (5,2)




Cluster 1

Alzheimer como Causa Básica

CID	Descrição
F00.0	Demência na doença de Alzheimer de início precoce
F00.1	Demência na doença de Alzheimer de início tardio
F00.2	Demência na doença de Alzheimer, tipo atípico ou misto
F00.9	Demência na doença de Alzheimer, não especificada
G30.0	Doença de Alzheimer de início precoce
G30.1	Doença de Alzheimer de início tardio
G30.8	Outras formas de doença de Alzheimer
G30.9	Doença de Alzheimer, não especificada

Cluster 2

Neurônio: (6,6)



Cluster 2

Alzheimer com Desassistência e Declínio Avançado

CID	Descrição	Frequência (%)
R99X	Outras causas mal definidas e não especificadas de mortalidade	70,3%
R98X	Morte sem assistência	18,8%
R54X	Senilidade	6,8%
R64X	Caquexia	3,0%
Outros	-	1,1%

Cluster 2

Alzheimer com Desassistência e Declínio Avançado

CID	Descrição	Frequência (%)
R99X	Outras causas mal definidas e não especificadas de mortalidade	70,3%
R98X	Morte sem assistência	18,8%
R54X	Senilidade	6,8%
R64X	Caquexia	3,0%
Outros	-	1,1%

- **Problemas no acesso à saúde e à qualidade da assistência** prestada, reforçando fragilidades no cuidado a pacientes com Alzheimer em estágio avançado

(Bahia. Secretaria de Saúde do Estado da Bahia, n.d.)

- Indivíduos deste cluster parecem ter passado por **isolamento social, abandono ou subnotificação clínica.**

(Pesquisa Semiestruturada biomédica em formação Geovanna Moreira)



Cluster 2

Alzheimer com Desassistência e Declínio Avançado


CID	Descrição	Frequência (%)
R99X	Outras causas mal definidas e não especificadas de mortalidade	70,3%
R98X	Morte sem assistência	18,8%
R54X	Senilidade	6,8%
R64X	Caquexia	3,0%
Outros	-	1,1%

- Senilidade e caquexia são sinais de Alzheimer em estágio terminal, onde o corpo perde função e massa.
(Venturini et al., 2022)

Cluster 3

Neurônio: (1,0)

Top 10 CIDs mais frequentes na LINHAII_1 Cluster3



Cluster 3

Alzheimer com Comorbidades Cardiovasculares

CID	Descrição	Frequência (%)
I10X	Hipertensão essencial (primária)	86,4%
L89X	Úlcera de decúbito (escaras)	6,4%
I64X	Acidente vascular cerebral, não especificado	3,6%
I48X	Fibrilação e flutter atrial	2,9%
Outros	-	0,7%



Cluster 3

Alzheimer com Comorbidades Cardiovasculares

CID	Descrição	Frequência (%)
I10X	Hipertensão essencial (primária)	86,4%
L89X	Úlcera de decúbito (escaras)	6,4%
I64X	Acidente vascular cerebral, não especificado	3,6%
I48X	Fibrilação e flutter atrial	2,9%
Outros	-	0,7%

- Hipertensão é altamente prevalente em pacientes com Alzheimer
- Afeta 30,2% a 73,9% dos casos (Lanctôt et al., 2024)
- A presença dessas comorbidades aumenta o risco de mortalidade (Wang et al., 2025)

Recomendações

- Integrar cuidados cardiovasculares ao cuidado em Alzheimer
- Criar sistemas de investigação epidemiológica para óbitos domiciliares
 - Validar e aprimorar protocolos atuais para reduzir uso de CIDs inespecíficos (ex: R99X, R98X)
- Validar clusters com prontuários eletrônicos
- Explorar diferenças regionais e demográficas
- Comparar SOM com outros algoritmos de clusterização
- Analisar o impacto da COVID-19 entre 2012–2022
- Criar modelos preditivos de risco para personalização do cuidado

Limitações

- Análise da Declaração de Óbito (**DO**) **não** necessariamente **abrange** todo o **histórico clínico** do paciente
- Dependência dos **parâmetros** → afeta **reprodutibilidade** dos clusters






**“O Alzheimer não rouba apenas memórias,
mas também a essência do que somos.”**



Gabriela Santana Camilo



Gabriel Vinícius Rocha Barboza



INSTITUTO FEDERAL
SÃO PAULO

Ataques Cardíacos em Mulheres Jovens: Uma Análise Baseada no SIM/DATASUS utilizando Mapas Auto-Organizáveis (SOM)



Motivação

16/06/2023

ADMIN

SAÚDE

O que explica aumento de mortalidade por infarto entre mulheres jovens brasileiras

Números de mulheres brasileiras de 18 a 49 anos vítimas de infarto aumentaram na última década.

“Infelizmente, essa é a realidade. O tratamento do infarto nas mulheres costuma ser inadequado e tardio”, classifica Mansur.

“As mulheres também são menos representadas em estudos clínicos de cardiologia. O número de voluntárias nas pesquisas é sempre muito menor”, aponta Jatene.


Ismep - Instituto Santa Marta de Ensino e Pesquisa


Aplicação do SOM


- Métrica cosseno e Manhattan
- Redefinindo parâmetros da base de dados

```
variaveis_desejadas = [  
    'LINHAA', 'LINHAA_1', 'LINHAA_2', 'LINHAA_3',  
    'LINHAB', 'LINHAB_1',  
    'LINHAC', 'LINHAC_1', 'LINHAC_2',  
    'LINHAD', 'LINHAD_1', 'LINHAD_2',  
    'LINHAII', 'LINHAII_1', 'LINHAII_2', 'LINHAII_3', 'LINHAII_4', 'LINHAII_5',  
    'CAUSABAS', 'CAUSABAS_0'  
]
```

Aplicação do SOM







Legenda - Variáveis representadas por cor

■ LINHAA	■ LINHAB_1	■ LINHAD_1	■ LINHAII_3
■ LINHAA_1	■ LINHAC	■ LINHAD_2	■ LINHAII_4
■ LINHAA_2	■ LINHAC_1	■ LINHAII	■ LINHAII_5
■ LINHAA_3	■ LINHAC_2	■ LINHAII_1	■ CAUSABAS
■ LINHAB	■ LINHAD	■ LINHAII_2	■ CAUSABAS_O

Resultados de CID´s da linha B e C presente dentro dos Neurônios:

CID-10	Descrição da Doença	Frequência (%)
R51X	Cefaleia (dor de cabeça)	4,76%
R58X	Hemorragia não especificada	4,76%
I10X	Hipertensão essencial (primária)	33,33%
J81X	Edema pulmonar	38,10%
J90X	Derrame pleural não classificado em outra parte	9,52%
I48X	Fibrilação e flutter atrial	4,76%
I21X	Infarto agudo do miocárdio	4,76%

LINHAB do neurônio 0,0

Código CID-10	Descrição	Frequência (%)
I219	Infarto agudo do miocárdio não especificado	11,90%
I210	Infarto agudo transmural da parede anterior do miocárdio	26,19%
I312	Hemopericárdio não classificado em outra parte	4,76%
I119	Cardiopatia hipertensiva sem insuficiência cardíaca	2,38%
I469	Parada cardíaca, não especificada	4,76%
I212	Infarto agudo transmural do miocárdio em outras localizações	9,52%
I259	Doença isquêmica crônica do coração, não especificada	2,38%
I110	Cardiopatia hipertensiva com insuficiência cardíaca	2,38%
I211	Infarto agudo transmural da parede inferior	7,14%
R072	Dor precordial	2,38%
R092	Parada respiratória	2,38%
I674	Encefalopatia hipertensiva	2,38%
I213	Infarto agudo transmural do miocárdio, localização não especificada	9,52%
J189	Pneumonia, agente não especificado	4,76%
I509	Insuficiência cardíaca, não especificada	2,38%
I500	Insuficiência cardíaca congestiva	4,76%

LINHAB do neurônio 0,1

Resultados de CID´s da linha B e C presente dentro dos Neurônios:

CID-10	Descrição da Doença	Frequência (%)
I219	Infarto agudo do miocárdio não especificado	42,86%
I519	Doença não especificada do coração	7,14%
I517	Cardiomegalia (aumento do coração)	7,14%
I119	Doença cardíaca hipertensiva sem insuficiência cardíaca (congestiva)	14,29%
J969	Transtorno respiratório não especificado	7,14%
I229	Infarto do miocárdio recorrente de localização não especificada	14,29%
I251	Doença aterosclerótica do coração	7,14%

LINHAC do neurônio 1,3


LINHAC do neurônio 3,3

CID-10	Descrição da Doença	Frequência (%)
J81X	Edema pulmonar	40,00%
I10X	Hipertensão essencial (primária)	40,00%
E86X	Depleção de volume (ou desidratação)	20,00%

Entrevista semiestruturada

- Entrevista realizada com profissional da saúde;
- Determinação de 4 fases clínicas

Linha Temporal da Doença – Avaliação Clínica



Resultados de análise de um profissional da saúde

Infarto Agudo do Miocárdio em Mulheres Jovens (18–40 anos)

CID-10	Descrição
I21.9	Infarto agudo do miocárdio não especificado
I21.0	Infarto agudo transmural da parede anterior do miocárdio
I21.1	Infarto agudo transmural da parede inferior
I21.2	Infarto agudo transmural em outras localizações
I21.3	Infarto transmural, localização não especificada
I22.9	Infarto do miocárdio recorrente de localização não especificada
I25.9	Doença isquêmica crônica do coração, não especificada
I46.9	Parada cardíaca, não especificada
I50.0 / I50.9	Insuficiência cardíaca congestiva e não especificada
I11.0 / I11.9	Cardiopatía hipertensiva (com/s/insuficiência cardíaca)
I48.X	Fibrilação e flutter atrial
R07.2	Dor precordial (sintoma associado a infarto)
I10.X	Hipertensão essencial (primária)
I31.2	Hemopericárdio não especificado



- Após destacar os principais CID'S de sua análise clinica ela fez uma linha temporal de padrões que podem ter levado essas mulheres a óbito.

Fase	Período Estimado	Principais CIDs/Condições
Condições de Base	Meses a anos	E86.X (Desidratação), I10.X (Hipertensão), fatores sociais
Fase Subclínica	Meses a anos	I11.9 (Cardiopatía hipertensiva), I25.X, I51.X (Doença cardíaca crônica)
Fase Aguda	Horas a dias	I21.9 / I21.0 (Infarto), R07.2 (Dor precordial), I48.X (Arritmia)
Fase Terminal	Minutos a horas	I46.9 (Parada cardíaca), R09.2 (Parada respiratória), J81.X (Edema), R58.X (Hemorragia)

Mulheres de 18 a 40 anos com infarto mostraram:

- 1. Alta prevalência de hipertensão primária e cardiopatía hipertensiva.
- 2. Episódios de insuficiência cardíaca, edema pulmonar, arritmias e parada cardíaca.



Principais CIDs/Condições
E86.X (Desidratação), I10.X (Hipertensão), fatores sociais
I11.9 (Cardiopatia hipertensiva), I25.X, I51.X (Doença cardíaca crônica)
I21.9 / I21.0 (Infarto), R07.2 (Dor precordial), I48.X (Arritmia)
I46.9 (Parada cardíaca), R09.2 (Parada respiratória), J81.X (Edema), R58.X (Hemorragia)

I10X	Hipertensão essencial (primária)	40,00%
E86X	Depleção de volume (ou desidratação)	20,00%
I119	Doença cardíaca hipertensiva sem insuficiência cardíaca (congestiva)	14,29%
I219	Infarto agudo do miocárdio não especificado	11,90%
I210	Infarto agudo transmural da parede anterior do miocárdio	26,19%



- **Linha C**

CID-10	Descrição da Doença	Frequência (%)
J81X	Edema pulmonar	40,00%
I10X	Hipertensão essencial (primária)	40,00%
E86X	Depleção de volume (ou desidratação)	20,00%

I119	Doença cardíaca hipertensiva sem insuficiência cardíaca (congestiva)	14,29%
------	--	--------

- A linha temporal clínica foi identificada na análise dos clusters;
- **LINHAA:** Causa imediata da morte;
- **LINHAC:** Causa intermediária anterior;
- Mulheres tendem a apresentar sintomas atípicos de infarto, o que leva a atrasos no diagnóstico.
- **Relação com fatores sociais e ambientais:** Estresse, negligência médica, alimentação inadequada...



Hipóteses para Infarto em Mulheres Jovens (com base nos padrões):

Categoria	Exemplos
Hormonal e vascular	Uso de anticoncepcionais + tabagismo = risco trombótico
Genético/familiar	História precoce de doença coronariana
Autoimune/Inflamatória	Lúpus, artrite reumatoide, vasculites
Metabólica	Obesidade, diabetes tipo 2 precoce
Estresse crônico	Alta liberação de catecolaminas pode causar espasmo coronariano
Condicionantes sociais	Falta de acesso ao cuidado preventivo

Mulheres de 18 a 40 anos com infarto mostraram:

1. Alta prevalência de hipertensão primária e cardiopatia hipertensiva
2. Episódios de insuficiência cardíaca, edema pulmonar, arritmias e parada cardíaca
3. Possivelmente associadas a fatores hormonais, inflamatórios, genéticos ou ambientais





“A juventude não é escudo contra doenças do coração. Valorize cada sinal, cada sintoma, cada oportunidade de se cuidar.”



Bianca Toledo



Giselle Silva

Próximos Passos...

Este roadmap delinea as principais fases do grupo de pesquisa, desde a estruturação inicial e documentação até a análise aprofundada e a disseminação dos resultados para aplicação prática.



Onboarding e Documentação

main 1 Branch 0 Tags <> Code

 **gabrielbarboza** 

8c4549c · 2 days ago  6 Commits

 etl	 etl documentation	3 days ago
 projects	 heart attack analysis	2 days ago
 README.md		2 days ago
 etl-instructions.md	 update docs	2 days ago

README ⋮

IFSP Data Analysis Research Group

Boas-vindas ao repositório do grupo de pesquisa em análise de dados do IFSP GRU!

Sobre o Repositório

Este repositório é dedicado a um grupo de pesquisa do Instituto Federal de São Paulo (IFSP) que realiza a análise de dados de saúde pública do Brasil utilizando dados do SIM/DATASUS. O objetivo é fornecer um ambiente de pesquisa reprodutível para futuros pesquisadores, com instruções claras sobre como realizar o processo de ETL (Extração, Transformação e Carga), como executar as análises de dados, quais conhecimentos foram encontrados e quais os próximos passos que podem ser tomados.

Estrutura de Pastas

O repositório está organizado da seguinte forma:

<https://github.com/gabrielbarboza/ifsp-data-analysis-research-group>

Onboarding e Documentação

Instruções de Execução do ETL

Este documento explica como executar os scripts `extract.sh` e `extract2.sh` no diretório `etl/`, detalhando o fluxo ETL conforme o diagrama `etl-activity-diagram.png`.

Atenção: A execução do script `extract.sh` pode levar entre 1h e 2h, pois o volume total de dados processados é de aproximadamente 16GB.

Visão Geral

A etapa do ETL deste projeto foi totalmente automatizada utilizando um script desenvolvido em Shell Script e um utilitário em Linguagem C. O processo realiza:

- **Download automático** dos arquivos de dados de mortalidade do SIM/DATASUS (anos 2012 a 2022).
- **Conversão de codificação** dos arquivos CSV para UTF-8, garantindo a correta leitura de caracteres especiais e acentuação.
- **Transformação** dos arquivos `.csv` em arquivos `.sql`, permitindo a carga automatizada no banco de dados MySQL.
- **Carga** dos dados no banco de dados.
- **Validação** por meio da comparação de volumetria entre os arquivos originais e os dados carregados no banco, identificando possíveis perdas ou falhas na importação.

Além dos dados principais, o script foi adaptado para realizar a conversão de charset e o carregamento de arquivos auxiliares, como os dicionários de idade, nacionalidade e CID. Essas tabelas auxiliares, criadas no banco, são fundamentais para análise e filtragem dos dados, especialmente porque informações sensíveis são disponibilizadas de forma codificada, em conformidade com a LGPD.

A escolha por Shell Script e C se deu pela eficiência e agilidade na manipulação de grandes volumes de dados, apresentando desempenho superior a outras linguagens como Java e Python para essas tarefas.

Dica: Consulte o diagrama `etl-activity-diagram.png` antes de iniciar para entender o fluxo completo.

Pré-requisitos

- Ambiente Linux ou WSL com bash.
- Ferramentas: `wget`, `iconv`, `mysql` (cliente), `wc`.
- Permissão de execução para scripts (`chmod +x extract.sh extract2.sh`).
- Binário `csvtosql-bin` compilado em `etl/csvtosql/`.
- Banco de dados MySQL acessível.

<https://github.com/gabrielbarboza/ifsp-data-analysis-research-group>



**“A vida só pode ser compreendida,
olhando-se para trás; mas só pode
ser vivida, olhando-se para frente.”**

Soren Kierkegaard



Gabriel Barboza



Gabriela Santana



Giselle Silva



Bianca Toledo



INSTITUTO FEDERAL
SÃO PAULO